

Fundamentos de la Ciencia de Datos
Cursada 2026
Práctico 2: Acceso a datos

Recuerden que este práctico no se entrega, tiene como propósito solamente que practiquen acceso a archivos, análisis preliminar de ellos, y algunos otros conceptos importantes de la materia.

1. Dado el conjunto de datos "ObesityDataSet_raw_and_data_synthetic", disponible en los siguientes links:
 - Descripción:
https://ignaciorlando.github.io/datasets/data-science/ObesityDataSet_raw_and_data_synthetic.txt
 - Archivo:
https://ignaciorlando.github.io/datasets/data-science/ObesityDataSet_raw_and_data_synthetic.csv
 - a) Implementar en una notebook de Jupyter el código necesario para:
 - i) Descargar automáticamente ambos archivos.
 - ii) Leer el archivo de descripción y mostrar su contenido en pantalla.
 - iii) Leer el archivo de datos.
 - iv) Imprimir la cabecera del archivo.
 - v) Imprimir los primeros 5 registros del archivo.
 - vi) Imprimir el resumen estadístico del mismo.
 - b) Analizar los valores de las columnas. ¿Qué tipo de datos hay en cada una? ¿Qué representan? Incluir información del análisis en la notebook.
2. Dado el conjunto de datos "netflix_titles", disponible en los siguientes links:
 - Descripción:
https://ignaciorlando.github.io/datasets/data-science/netflix_titles.txt
 - Archivo: https://ignaciorlando.github.io/datasets/data-science/netflix_titles.csv
 - c) Implementar en una notebook de Jupyter el código necesario para:
 - i) Descargar automáticamente ambos archivos.
 - ii) Leer el archivo de descripción y mostrar su contenido en pantalla.
 - iii) Abrir el archivo usando Excel, Google Sheets o cualquier otra hoja de cálculo. ¿Qué consideraciones vas a tener que tener en cuenta al momento de abrir el archivo usando Python?
 - iv) Abrir el archivo CSV utilizando Python, teniendo en cuenta las consideraciones del punto anterior.
 - v) Imprimir la cabecera del archivo.
 - vi) Imprimir los primeros 5 registros del archivo.
 - vii) Imprimir el resumen estadístico del mismo. ¿Hay columnas que faltan en el análisis? Explorar por qué.
 - d) Analizar los valores de las columnas. ¿Qué tipo de datos hay en cada una? ¿Qué representan? Incluir información del análisis en la notebook.
 - e) Responder las siguientes preguntas:
 - i) ¿Cuántos directores distintos hay?

- ii) ¿Quién es el director con más películas?
 - iii) ¿Cuántas series hay? ¿Y cuántos programas de TV?
 - iv) ¿Cuál es la película más vieja del catálogo? ¿Y la serie?
 - v) Dado un país, determinar cuántas películas de ese país hay en la base de datos.
- 3. Dado el conjunto de datos “catalogo_streaming_argentina_2024”, disponible en el link:
https://ignaciorlando.github.io/datasets/data-science/catalogo_streaming_argentina_2024.xlsx
 - a) Implementar en una notebook de Jupyter el código necesario para:
 - i) Descargar automáticamente el archivo.
 - ii) Leer el archivo.
 - iii) Imprimir la cabecera del archivo.
 - iv) Imprimir los primeros 5 registros del archivo.
 - v) Imprimir el resumen estadístico del mismo.
 - b) Analizar los valores de las columnas. ¿Qué tipo de datos hay en cada una? ¿Qué representan? Incluir información del análisis en la notebook.
 - c) Proponer una serie de análisis propios, similar a los abordados en el punto (2) inciso (e). ¡Sean imaginativos!

Preguntas tipo parcial para practicar sin computadora:

1. Sobre el conjunto “ObesityDataSet_raw_and_data_synthetic”, hacer un describe() y luego responder:
 - a. Por qué variables como FCVC, NCP y FAF presentan valores decimales aunque su documentación las describe mediante categorías o cantidades discretas. ¿Consideraría esto un error, una transformación válida o una limitación de confiabilidad?
 - b. Qué tratamiento aplicaría a cada uno de los siguientes elementos antes de analizar los datos: registros duplicados, variables binarias almacenadas como texto, variables ordinales y MTRANS. Justifique cuándo conservaría el orden entre categorías y cuándo utilizaría one-hot encoding.
 - c. Formule tres hipótesis univariadas. Para cada una, indique cómo las evaluaría.
 - d. ¿Hasta qué población considera que podrían generalizarse las conclusiones obtenidas? Analice específicamente el país de origen de los participantes y el hecho de que la mayoría de los registros sea sintética.
2. Al intentar leer el conjunto “netflix_titles.csv” con la configuración predeterminada de pd.read_csv(), se obtuvo un error de decodificación UTF-8. Al utilizar codificación latin1, Pandas informó 8809 filas y 26 columnas, con catorce columnas con nombres como Unnamed: 12, Unnamed: 13, etc., completamente vacías. Además, de los 2634 valores faltantes de director, 2446 corresponden a programas de televisión y 188 a películas.
 - a. Diagnostique los dos problemas principales encontrados al leer el archivo: el error de codificación y la aparición de catorce columnas adicionales. Indique cómo verificaría que el archivo fue leído correctamente y qué tratamiento aplicaría sobre las columnas Unnamed.

- b. La columna duration contiene valores como 90 min para películas y 2 Seasons para programas de televisión. Explique por qué no representa una única variable cuantitativa directamente comparable y proponga una transformación que permita analizarla correctamente.
 - c. Analice los valores faltantes de director, cast y country. ¿Eliminaría todos los registros incompletos? Considere especialmente la relación observada entre la ausencia de director y el tipo de contenido.
 - d. Al contar contenidos argentinos mediante `country == "Argentina"` se obtienen 56 registros. Al separar los países enumerados en cada celda y buscar la categoría Argentina, se obtienen 91. Explique la diferencia y determine qué estrategia responde mejor a la pregunta “¿cuántos contenidos del catálogo tienen participación argentina?”.
 - e. Proponga tres análisis exploratorios que puedan implementarse mediante filtros, `groupby()`, `value_counts()` y ordenamiento. Al menos uno debe comparar películas y programas de televisión, y otro debe considerar el año de estreno.
3. Dado el conjunto “catalogo_streaming_argentina_2024.xlsx”
 - a. Determine cuál parece ser la unidad de observación del conjunto. ¿Cada fila representa una obra audiovisual o la disponibilidad de una obra en una plataforma? Explique cómo afecta esta decisión al cálculo del tamaño de cada catálogo.
 - b. Analice las repeticiones de title y de la combinación title–platform. ¿Cuáles pueden ser registros válidos y cuáles requieren una investigación por posibles duplicados? Proponga una clave identificadora adecuada, teniendo en cuenta que distintas obras pueden compartir título.
 - c. Proponga una estrategia para los valores faltantes de imdbVotes, imdbScore, tmdbScore, genres y director. ¿Qué diferencia existe entre un valor nulo y `runtime = 0`? ¿Cómo verificaría si ese cero es válido o representa un faltante codificado incorrectamente?
 - d. Analice las distribuciones de imdbVotes y tmdbPopularity a partir de la media, la mediana, el desvío y el máximo. ¿Qué indican respecto de la asimetría y de la posible presencia de valores extremos? ¿Aplicaría automáticamente una eliminación de outliers?
 - e. Proponga una transformación para year_range que permita distinguir entre año puntual, año inicial y año final.